

# 10 Reguläre Ausdrücke und rechtslineare Grammatiken

## 10.1 Reguläre Ausdrücke

### Klammereinsparungsregeln

- sind wohl sinnvoll und naheliegend gewählt
- muss man daher hoffentlich nicht groß auswendig lernen
- zumal es dann für  $\langle R \rangle$  sowieso egal ist, ob man von links oder von rechts klammert: z. B.  $\langle \langle (aa)b \rangle \rangle = \langle (a(ab)) \rangle = \{aab\}$

### durch regulären Ausdruck beschriebene formale Sprache

- weitere Beispiele der Form „von  $R$  zu  $\langle R \rangle$ “
  - $R = (a|b)*abb(a|b)*$ : ...  $\langle R \rangle$  enthält genau die Wörter, in denen das Teilwort  $abb$  vorkommt.
  - $R = a**$ :  $\langle R \rangle = \{a\}^*$ . Zwei Sterne unmittelbar hintereinander sind nicht besser als einer.
- weitere Beispiele der Form „von  $\langle R \rangle$  zu  $R$ “
  - $R$  für die Sprache aller Wörter, in denen mindestens drei  $b$  vorkommen:  
 $(a|b)*b(a|b)*b(a|b)*b(a|b)*$   
wer „optimieren“ will: z. B.  $a*ba*ba*b(a|b)*$
  - $R$  für die Sprache  $\{\varepsilon\}$ :  $\emptyset*$ , denn  $\langle \emptyset* \rangle = \langle \emptyset \rangle^* = \{\}^* = \{\varepsilon\}$
  - $R$  für die Sprache aller Wörter, in denen nirgends das Teilwort  $ab$  vorkommt:  $b*a*$
  - Wenn  $R$  ein regulärer Ausdruck für eine formale Sprache  $L = \langle R \rangle$  ist, wie sieht dann ein regulärer Ausdruck
    - \* für  $L^*$  aus:  $(R)*$
    - \* für  $L^+$  aus:  $R(R)*$
- Bitte ggf. erläutern, dass  $(\{a\}^*\{b\}^*)^* = \{a,b\}^*$  ist: Man kann jedes Wort zerhacken in eine Folge von Blöcken, von denen jeder ein Teilwort aus  $a$ 's gefolgt von einem Teilwort aus  $b$ 's ist.

## Beweis von Äquivalenzen im Kreis

- ggf. noch mal erläutern
- Konsequenz: wenn man z. B. zu regulärem Ausdruck äquivalenten endlichen Akzeptor konstruieren will, muss man dem Umweg über rechtslineare Grammatik machen. In der Praxis vielleicht unpraktisch: aber es gibt auch direkte Konstruktionen.

## 10.2 Rechtslineare Grammatiken

### Beispiel rechtslinearer Grammatiken

- *Das hier ist keine rechtslineare Grammatik:*  
 $G = (\{X, Y\}, \{a, b\}, X, \{X \rightarrow aY \mid \varepsilon, Y \rightarrow Xb\})$


Die Grammatik ist zwar (wie man auch sagt) linear, aber nicht *rechtslinear*, denn die Produktion  $Y \rightarrow Xb$  hat das Nichtterminalsymbol nicht am rechten Ende.

Da  $L(G) = \{a^k b^k \mid k \in \mathbb{N}_0\}$ , sieht man deutlich, dass das Mischen von rechts- und linkslinearen Produktionen zu mehr als regulären Sprachen führt.

- von  $G$  zu  $L(G)$ : betrachte  $G = (\{X, Y, Z\}, \{a, b\}, X, P)$  mit  $P = \{X \rightarrow aX \mid bY \mid \varepsilon, Y \rightarrow aX \mid bZ \mid \varepsilon, Z \rightarrow aZ \mid bZ\}$

Was ist  $L(G)$ ?

Was hat diese Grammatik mit dem folgenden Automaten aus der vorigen Einheit zu tun?




- Natürlich könnte man die Grammatik vereinfachen:  $G = (\{X, Y\}, \{a, b\}, X, P)$  mit  $P = \{X \rightarrow aX \mid bY \mid \varepsilon, Y \rightarrow aX \mid \varepsilon\}$  erzeugt die gleiche Sprache.
- Wer findet eine noch einfachere Lösung?  
 $G = (\{X\}, \{a, b\}, X, P)$  mit  $P = \{X \rightarrow aX \mid baX \mid b \mid \varepsilon\}$

## 10.3 Kantorowitsch-Bäume und strukturelle Induktion

### Kantorowitsch-Bäume

Kantorowitsch-Bäume werden nicht formal eingeführt. Zur weiteren Erläuterung vielleicht auch noch mal einen arithmetischen Ausdruck wie  $3 + (a + b) * (-c)$  umwandeln in



### Regex-Bäume

Das ist natürlich kein feststehender Begriff. Wer wird nur benutzt, um sich nicht den Mund fusselig zu reden.

### Höhe von Bäumen

Kann man auch definieren als Länge der längsten (wiederholungsfreien) Wege von der Wurzel zu irgendwelchen Blättern.

Eventuell die etwas lasche Formulierung des Falles „ $1 + \max_i h(U_i)$ , falls ...“ erläutern

## 10.4 alte Klausuraufgabe

Auf die Schnelle habe ich zu regulären Ausdrücken/Akzeptoren Aufgabe 4 aus der September 2010 Klausur gefunden, gibt aber sicherlich noch mehr alte Aufgaben:

<http://gbi.ira.uka.de/archiv/2009/k-sep10.pdf>